COMPTE RENDU

1. Objectif du projet

L'objectif de ce projet est de constituer un corpus de textes qui pourra être utilisé pour entraîner un réseau de neurones capable de reconnaître automatiquement le thème d'un texte. Les quatre catégories étudiées sont l'astronomie, la cuisine, le football et la peinture.

Ce projet permet de mettre en pratique plusieurs techniques de collecte de données sur le Web, notamment l'utilisation d'une API, l'exploration de catégories et le scraping de pages HTML. Il constitue une première étape dans la préparation des données nécessaires à un projet de classification automatique de textes.

2. Méthodologie de collecte des données

La collecte s'appuie sur Wikipédia en anglais. Deux approches complémentaires sont utilisées : l'API MediaWiki pour rechercher les catégories et récupérer leurs membres, et le scraping pour extraire le contenu textuel des articles.

La bibliothèque `requests` permet d'effectuer les requêtes HTTP, tandis que `BeautifulSoup` sert à analyser le HTML des pages. La bibliothèque `pandas` est utilisée pour organiser les données dans un tableau.

Les catégories de départ correspondent aux thèmes suivants : *Astronomy*, *Cooking*, *Painting* et *Association football*. Le programme explore les catégories et leurs sous-catégories afin de trouver des articles pertinents. La profondeur d'exploration et le nombre d'articles recherchés sont limités pour maîtriser le volume de collecte.

Pour chaque article, le programme récupère son titre et un paragraphe suffisamment long. Les éléments inutiles, comme certaines références de notes, sont retirés afin de conserver un texte exploitable.

La collecte respecte également plusieurs bonnes pratiques : consultation du fichier `robots.txt`, utilisation d'un `User-Agent` descriptif, pauses entre les requêtes et prise en compte des erreurs HTTP. Ces précautions contribuent à limiter la charge sur le serveur et à rendre la collecte plus responsable.

3. Nettoyage et préparation du corpus

Après la collecte, les données sont regroupées dans un DataFrame `pandas`. Le nettoyage consiste à supprimer les articles ayant un titre en double et les lignes contenant des valeurs manquantes. Cette étape permet d'améliorer la qualité du corpus avant son utilisation.

Le programme calcule ensuite le nombre de textes disponibles dans chaque catégorie ainsi que la longueur médiane des textes, exprimée en nombre de mots. Enfin, les données nettoyées sont sauvegardées dans le fichier `corpus.csv`, sans index supplémentaire, afin de pouvoir être réutilisées dans les étapes suivantes.

4. Synthèse des résultats

Indicateur	Résultat
Textes en astronomie	60
Textes en cuisine	60
Textes en football	60
Textes en peinture	59
Total des textes	**239**
Longueur médiane	**65 mots**
Fichier de sortie	`corpus.csv`

Le corpus final comprend **239 textes répartis sur quatre catégories**. La distribution est presque équilibrée : trois catégories contiennent 60 textes et la peinture en contient 59. L'écart d'un seul texte reste faible et permet de disposer d'un ensemble de données relativement homogène en nombre d'exemples par classe.

La longueur médiane de 65 mots indique que la moitié des textes comporte au plus 65 mots et l'autre moitié au moins 65 mots. Elle donne une indication de la taille des textes collectés, mais ne garantit pas à elle seule que leur contenu soit suffisamment représentatif de chaque thème.

5. Analyse et limites

L'utilisation d'une API est généralement préférable lorsqu'elle fournit les informations recherchées dans un format structuré : les données sont plus faciles à récupérer et moins dépendantes de la présentation des pages. Le scraping reste utile pour extraire des éléments précis qui ne sont pas directement disponibles dans l'API.

Le corpus obtenu constitue une première base de travail, mais il présente certaines limites. Le nombre de textes reste relativement faible pour un projet d'apprentissage automatique, et les paragraphes collectés peuvent ne pas représenter l'ensemble du contenu des articles. De plus, une répartition équilibrée ne garantit pas que les quatre catégories soient faciles à distinguer.

Pour améliorer le projet, il serait possible d'augmenter progressivement le nombre de textes, de vérifier leur pertinence et leur qualité, puis de conserver un suivi des erreurs de collecte. Pour un volume beaucoup plus important, une solution de stockage persistante et une gestion plus robuste des requêtes seraient également nécessaires.

6. Conclusion

Ce projet m'a permis de découvrir les principales étapes de constitution d'un corpus textuel : recherche des catégories, collecte des articles, extraction du texte, nettoyage et sauvegarde des données. L'utilisation de Python, de `requêtes`, de `BeautifulSoup` et de `pandas` m'a permis de mettre en pratique des outils essentiels pour la collecte et la préparation des données.

Le résultat obtenu est un corpus nettoyé de 239 textes, répartis entre quatre thèmes et sauvegardés dans `corpus.csv`. Ce corpus constitue une première étape vers la création d'un réseau de neurones capable de classer automatiquement des textes. La suite du travail consistera à préparer les données pour l'apprentissage, à entraîner le modèle et à évaluer ses performances sur des données de test.